Regresion Lineal

Catherine Rojas

2024-08-30

La recta de mejor ajuste (Primera entrega)

```
library(readr)

## Warning: package 'readr' was built under R version 4.3.3

data <- read_csv("Estatura-peso_HyM.csv")

## Rows: 440 Columns: 3
## ── Column specification
────────────────────────────────────────────────────────
## Delimiter: ","
## chr (1): Sexo
## dbl (2): Estatura, Peso
##
## ℹ Use `spec()` to retrieve the full column specification for this
data.
## ℹ Specify the column types or set `show_col_types = FALSE` to quiet
this message.
```

1. Obtén la matriz de correlación de los datos que se te proporcionan. Interpreta.

```
dataM = subset(data, data$Sexo=="M")
dataH = subset(data, data$Sexo == "H")
data1 = data.frame(dataH$Estatura, dataH$Peso, dataM$Estatura,
dataM$Peso)

# Matriz de correlación
correlation_matrix <- cor(data1)

# Mostrar resultados
print("Matriz de correlación:")

## [1] "Matriz de correlación:"

correlation_matrix

##                dataH.Estatura  dataH.Peso dataM.Estatura dataM.Peso
## dataH.Estatura   1.0000000000 0.846834792   0.0005540612 0.04724872
## dataH.Peso       0.8468347920 1.000000000   0.0035132246 0.02154907
```

```
## dataM.Estatura   0.0005540612 0.003513225   1.0000000000 0.52449621
## dataM.Peso       0.0472487231 0.021549075   0.5244962115 1.00000000
```

Interpretación

- Hombres: Existe una fuerte relación entre estatura y peso, lo que sugiere que a mayor estatura, mayor peso.
- Mujeres: Existe una correlación positiva moderada entre estatura y peso.
- Relaciones cruzadas: Las estaturas y pesos entre hombres y mujeres no muestran correlaciones significativas entre sí, indicando que estos grupos se comportan de manera independiente en términos de las variables consideradas.

2. Obtén medidas (media, desviación estándar, etc) que te ayuden a analizar los datos.

```r
# Función para calcular todas las medidas estadísticas
calcular_medidas <- function(df, variable) {
  medidas <- data.frame(
    Medida = c("Media", "Mediana", "Mínimo", "Máximo", "Q1", "Q3",
"Desviación Estándar"),
    Valor = c(mean(df[[variable]], na.rm = TRUE),
              median(df[[variable]], na.rm = TRUE),
              min(df[[variable]], na.rm = TRUE),
              max(df[[variable]], na.rm = TRUE),
              quantile(df[[variable]], 0.25, na.rm = TRUE),
              quantile(df[[variable]], 0.75, na.rm = TRUE),
              sd(df[[variable]], na.rm = TRUE))
  )
  return(medidas)
}

# Calcular medidas para estatura y peso de hombres
medidas_estatura_hombres <- calcular_medidas(dataH, "Estatura")
medidas_peso_hombres <- calcular_medidas(dataH, "Peso")

# Calcular medidas para estatura y peso de mujeres
medidas_estatura_mujeres <- calcular_medidas(dataM, "Estatura")
medidas_peso_mujeres <- calcular_medidas(dataM, "Peso")

# Crear un solo data.frame consolidado con todas las medidas
resultados <- data.frame(
  Medida = medidas_estatura_hombres$Medida,
  Hombres_Estatura = medidas_estatura_hombres$Valor,
  Mujeres_Estatura = medidas_estatura_mujeres$Valor,
  Hombres_Peso = medidas_peso_hombres$Valor,
  Mujeres_Peso = medidas_peso_mujeres$Valor
```

```
)

resultados

##                 Medida Hombres_Estatura Mujeres_Estatura Hombres_Peso
## 1                Media       1.65372727       1.57295455    72.857682
## 2              Mediana       1.65000000       1.57000000    72.975000
## 3               Mínimo       1.48000000       1.44000000    56.430000
## 4               Máximo       1.80000000       1.74000000    90.490000
## 5                   Q1       1.61000000       1.54000000    68.257500
## 6                   Q3       1.70000000       1.61000000    77.522500
## 7 Desviación Estándar       0.06173088       0.05036758     6.900354
##   Mujeres_Peso
## 1    55.083409
## 2    54.485000
## 3    37.390000
## 4    80.870000
## 5    49.355000
## 6    59.795000
## 7     7.792781
```

Observaciones * Los hombres son en promedio, más altos y pesan más que las mujeres. * Los datos de peso presentan mayor variabilidad en las mujeres, lo que sugiere que el peso de las mujeres varía más ampliamente que el de los hombres.

3. Encuentra la ecuación de regresión de mejor ajuste:

```
# Ajustar el modelo de regresión para hombres
modelo_hombres <- lm(Peso ~ Estatura, data = dataH)


# Ajustar el modelo de regresión para mujeres
modelo_mujeres <- lm(Peso ~ Estatura, data = dataM)

# Ajustar el modelo de regresión general
modelo <- lm(Peso ~ Estatura + Sexo, data)


# Mostrar los resultados del modelo
summary(modelo_hombres)

##
## Call:
## lm(formula = Peso ~ Estatura, data = dataH)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -8.3881 -2.6073 -0.0665  2.4421 11.1883
##
```

```
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -83.685      6.663  -12.56   <2e-16 ***
## Estatura      94.660      4.027   23.51   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.678 on 218 degrees of freedom
## Multiple R-squared:  0.7171, Adjusted R-squared:  0.7158
## F-statistic: 552.7 on 1 and 218 DF,  p-value: < 2.2e-16
```

```
summary(modelo_mujeres)
```

```
##
## Call:
## lm(formula = Peso ~ Estatura, data = dataM)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -21.3256  -4.1942   0.4004   4.2724  17.9114
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -72.560     14.041  -5.168 5.34e-07 ***
## Estatura      81.149      8.922   9.096  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 6.65 on 218 degrees of freedom
## Multiple R-squared:  0.2751, Adjusted R-squared:  0.2718
## F-statistic: 82.73 on 1 and 218 DF,  p-value: < 2.2e-16
```

```
summary(modelo)
```

```
##
## Call:
## lm(formula = Peso ~ Estatura + Sexo, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -21.9505  -3.2491   0.0489   3.2880  17.1243
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) -74.7546     7.5555  -9.894   <2e-16 ***
## Estatura     89.2604     4.5635  19.560   <2e-16 ***
## SexoM       -10.5645     0.6317 -16.724   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.381 on 437 degrees of freedom
```

```
## Multiple R-squared:  0.7837, Adjusted R-squared:  0.7827
## F-statistic: 791.5 on 2 and 437 DF,  p-value: < 2.2e-16

# Obtener la ecuación de regresión para hombres
cat("Ecuación de regresión para hombres modelo: Peso =",
coef(modelo_hombres)[1], "+", coef(modelo_hombres)[2], "* Estatura\n")

## Ecuación de regresión para hombres modelo: Peso = -83.68454 + 94.66024
* Estatura

# Obtener la ecuación de regresión para mujeres
cat("Ecuación de regresión para mujeres modelo : Peso =",
coef(modelo_mujeres)[1], "+", coef(modelo_mujeres)[2], "* Estatura\n")

## Ecuación de regresión para mujeres modelo : Peso = -72.56045 +
81.14911 * Estatura

# Obtener la ecuación de regresión para hombres
cat("Ecuación de regresión para el modelo general: Peso =",
coef(modelo)[1], "+", coef(modelo)[2], "* Estatura\n")

## Ecuación de regresión para el modelo general: Peso = -74.7546 +
89.26035 * Estatura
```

4. Realiza la regresión entre las variables involucradas

```
# Gráfico para hombres
plot(data1$dataH.Estatura, data1$dataH.Peso, main = "Hombres: Estatura vs
Peso", xlab = "Estatura", ylab = "Peso", pch = 19, col = "blue")
abline(modelo_hombres, col = "red", lwd = 2)
```

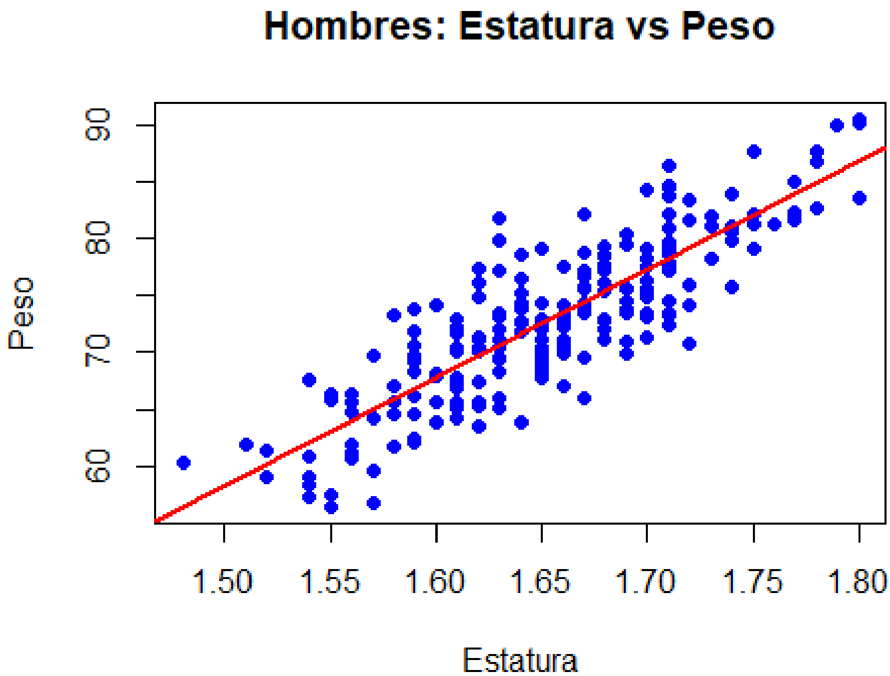


```r
# Gráfico para mujeres
plot(data1$dataM.Estatura, data1$dataM.Peso, main = "Mujeres: Estatura vs Peso", xlab = "Estatura", ylab = "Peso", pch = 19, col = "pink")
abline(modelo_mujeres, col = "red", lwd = 2)
```

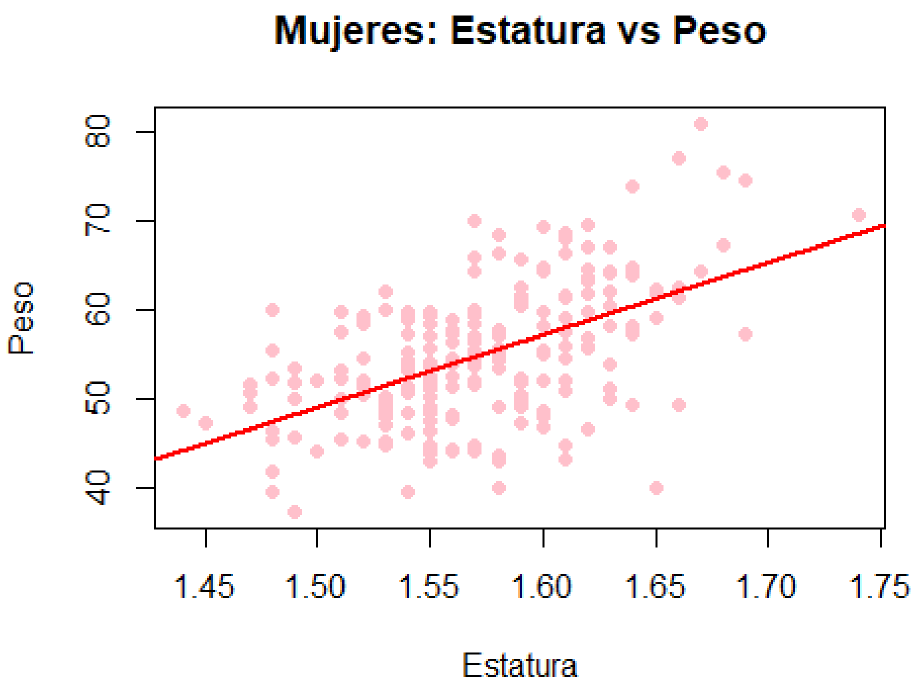


```r
# Gráfico de estatura vs peso con distinción por sexo
plot(data$Estatura, data$Peso, col = ifelse(data$Sexo == "H", "blue", "pink"), pch = 19,
     xlab = "Estatura", ylab = "Peso", main = "Estatura vs Peso con Sexo",
     xlim = c(min(data$Estatura), max(data$Estatura)),
     ylim = c(min(data$Peso), max(data$Peso)))

# Añadir líneas de regresión por sexo
abline(lm(Peso ~ Estatura, data = subset(data, Sexo == "H")), col = "blue", lwd = 2)
abline(lm(Peso ~ Estatura, data = subset(data, Sexo == "M")), col = "pink", lwd = 2)

# Añadir leyenda
legend("topright", legend = c("Hombres", "Mujeres"), col = c("blue", "pink"), lwd=2,pch=19)
```

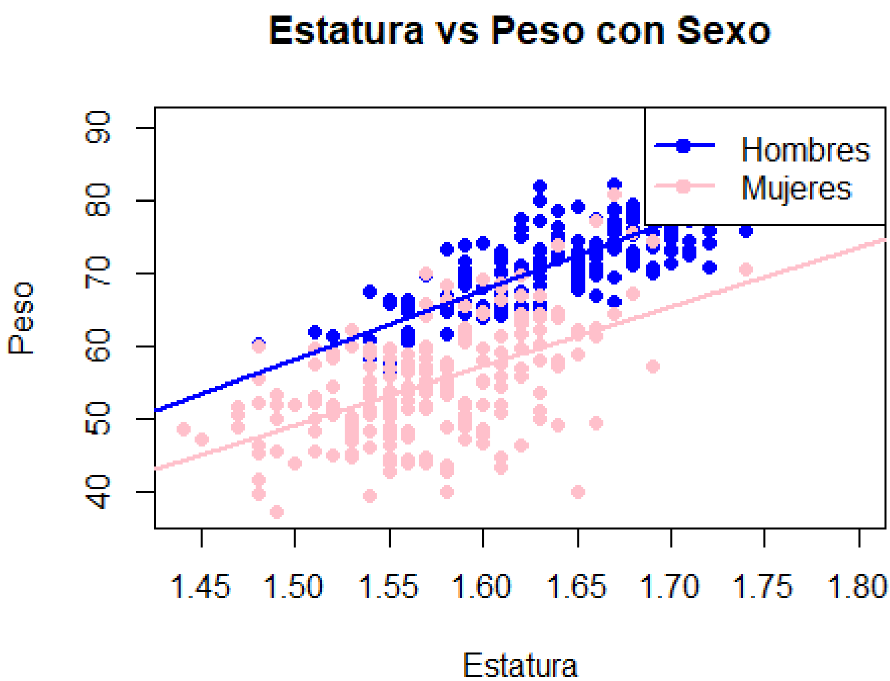


```
# Gráfico general
plot(data$Estatura, data$Peso, main = "Estatura vs Peso", xlab =
"Estatura", ylab = "Peso", pch = 19, col = "green")
abline(modelo, col = "red", lwd = 2)

## Warning in abline(modelo, col = "red", lwd = 2): only using the first
two of 3
## regression coefficients
```

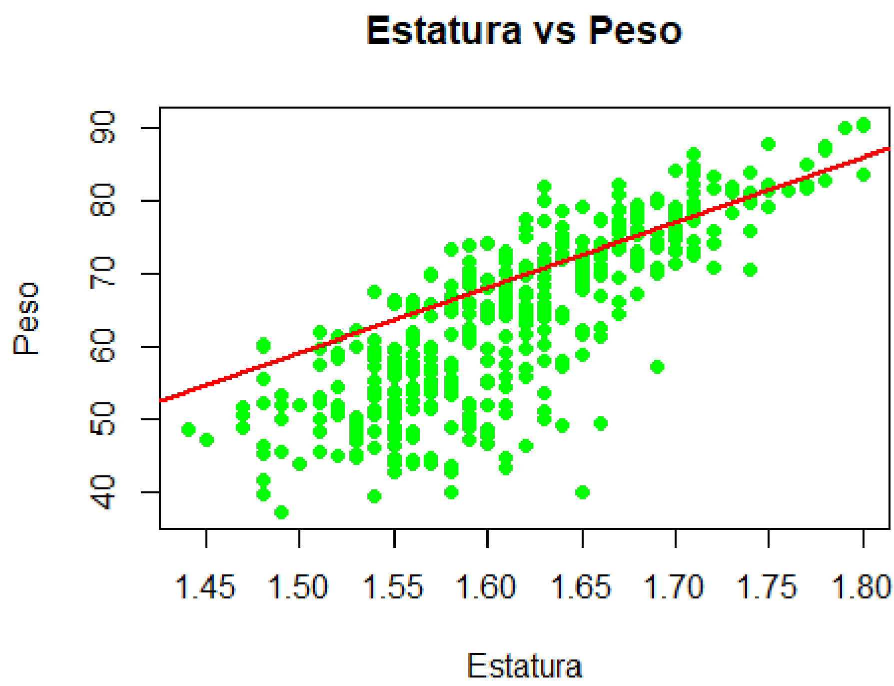

Interpretaciones de los modelos

- Comparación entre Hombres y Mujeres:

La estatura es un predictor más fuerte del peso para los hombres que para las mujeres, como lo indica el R^2 más alto en el modelo para hombres. Por otro lado, el modelo para mujeres tiene un R^2 significativamente más bajo, lo que sugiere que la estatura no es tan buen predictor del peso en mujeres como lo es en hombres.

- Modelo General: Cuando se incluyen tanto la estatura como el sexo en el modelo, se explica una mayor proporción de la variabilidad en el peso (78.27%), lo que indica que ambos factores son importantes para predecir el peso.

5. Verifica el modelo:

Hipótesis para el modelo:

$H_0: \beta = 0$ (El coeficiente del predictor en el modelo no es significativo)

$H_1: \beta \neq 0$ (El coeficiente del predictor en el modelo es significativo)

a) Verifica la significancia del modelo con un alfa de 0.03.

```
# Resumen del modelo para obtener valores p
summary_hombres <- summary(modelo_hombres)
summary_mujeres <- summary(modelo_mujeres)
```

```r
summary_general <- summary(modelo)

# Extraer los valores p del modelo para hombres y mujeres
p_value_hombres <- summary_hombres$coefficients[2, 4]
p_value_mujeres <- summary_mujeres$coefficients[2, 4]
p_value_general <- summary_general$coefficients[2, 4]

# Verificar la significancia con un alfa de 0.03
alpha <- 0.03

cat("Significancia del modelo para Hombres:\n")

## Significancia del modelo para Hombres:

if (p_value_hombres < alpha) {
  cat("El modelo es significativo (p-value =", p_value_hombres, "<",
alpha, ").\n")
} else {
  cat("El modelo no es significativo (p-value =", p_value_hombres, ">=",
alpha, ").\n")
}

## El modelo es significativo (p-value = 1.063532e-61 < 0.03 ).

cat("\nSignificancia del modelo para Mujeres:\n")

##
## Significancia del modelo para Mujeres:

if (p_value_mujeres < alpha) {
  cat("El modelo es significativo (p-value =", p_value_mujeres, "<",
alpha, ").\n")
} else {
  cat("El modelo no es significativo (p-value =", p_value_mujeres, ">=",
alpha, ").\n")
}

## El modelo es significativo (p-value = 5.997517e-17 < 0.03 ).

cat("\nSignificancia del modelo general:\n")

##
## Significancia del modelo general:

if (p_value_general < alpha) {
  cat("El modelo es significativo (p-value =", p_value_general, "<",
alpha, ").\n")
} else {
  cat("El modelo no es significativo (p-value =", p_value_general, ">=",
alpha, ").\n")
}
```

```
## El modelo es significativo (p-value = 1.179664e-61 < 0.03 ).
```

b) Verifica la significancia de β̂i con un alfa de 0.03.

Hipótesis para el intercepto (β_0) los modelos:

$$H_0: \beta = 0 \quad \text{(El intercepto del modelo no es significativo)}$$
$$H_1: \beta \neq 0 \quad \text{(El intercepto del modelo es significativo)}$$

Hipótesis para la pendiente (β_1) en el modelo de hombres (Estatura):

$$H_0: \beta = 0 \quad \text{(La pendiente del modelo no es significativa)}$$
$$H_1: \beta \neq 0 \quad \text{(La pendiente del modelo es significativa)}$$

```
# Extraer los valores p para el intercepto y la pendiente (Estatura)
p_value_intercepto_hombres <- summary_hombres$coefficients[1, 4]
p_value_intercepto_mujeres <- summary_mujeres$coefficients[1, 4]
p_value_intercepto_general <- summary_general$coefficients[1, 4]

# Verificar la significancia con un alfa de 0.03
alpha <- 0.03

cat("Significancia de los coeficientes para Hombres:\n")

## Significancia de los coeficientes para Hombres:

cat("Intercepto (β0):\n")

## Intercepto (β0):

if (p_value_intercepto_hombres < alpha) {
  cat("Significativo (p-value =", p_value_intercepto_hombres, "<", alpha,
").\n")
} else {
  cat("No significativo (p-value =", p_value_intercepto_hombres, ">=",
alpha, ").\n")
}

## Significativo (p-value = 1.410453e-27 < 0.03 ).

cat("Pendiente (β1 - Estatura):\n")

## Pendiente (β1 - Estatura):

if (p_value_hombres < alpha) {
  cat("Significativo (p-value =", p_value_hombres, "<", alpha, ").\n")
} else {
  cat("No significativo (p-value =", p_value_hombres, ">=", alpha,
```

```
").\n")
}

## Significativo (p-value = 1.063532e-61 < 0.03 ).

cat("\nSignificancia de los coeficientes para Mujeres:\n")

##
## Significancia de los coeficientes para Mujeres:

cat("Intercepto (β0):\n")

## Intercepto (β0):

if (p_value_intercepto_mujeres < alpha) {
  cat("Significativo (p-value =", p_value_intercepto_mujeres, "<", alpha,
").\n")
} else {
  cat("No significativo (p-value =", p_value_intercepto_mujeres, ">=",
alpha, ").\n")
}

## Significativo (p-value = 5.342762e-07 < 0.03 ).

cat("Pendiente (β1 - Estatura):\n")

## Pendiente (β1 - Estatura):

if (p_value_mujeres < alpha) {
  cat("Significativo (p-value =", p_value_mujeres, "<", alpha, ").\n")
} else {
  cat("No significativo (p-value =", p_value_mujeres, ">=", alpha,
").\n")
}

## Significativo (p-value = 5.997517e-17 < 0.03 ).

cat("\nSignificancia de los coeficientes General:\n")

##
## Significancia de los coeficientes General:

cat("Intercepto (β0):\n")

## Intercepto (β0):

if (p_value_intercepto_general < alpha) {
  cat("Significativo (p-value =", p_value_intercepto_general, "<", alpha,
").\n")
} else {
  cat("No significativo (p-value =", p_value_intercepto_general, ">=",
alpha, ").\n")
}
```

```
## Significativo (p-value = 5.821123e-21 < 0.03 ).

cat("Pendiente (β1 - Estatura):\n")

## Pendiente (β1 - Estatura):

if (p_value_general < alpha) {
  cat("Significativo (p-value =", p_value_general, "<", alpha, ").\n")
} else {
  cat("No significativo (p-value =", p_value_general, ">=", alpha,
").\n")
}

## Significativo (p-value = 1.179664e-61 < 0.03 ).
```

c) Verifica el porcentaje de variación explicada por el modelo

```
# Extraer el valor de R-cuadrado para cada modelo
r_squared_hombres <- summary_hombres$r.squared
r_squared_mujeres <- summary_mujeres$r.squared
r_squared_general <- summary_general$r.squared

# Mostrar el porcentaje de variación explicada por el modelo
cat("Porcentaje de variación explicada por el modelo para Hombres:",
r_squared_hombres * 100, "%\n")

## Porcentaje de variación explicada por el modelo para Hombres: 71.71292
%

cat("Porcentaje de variación explicada por el modelo para Mujeres:",
r_squared_mujeres * 100, "%\n")

## Porcentaje de variación explicada por el modelo para Mujeres: 27.50963
%

cat("Porcentaje de variación explicada por el modelo general:",
r_squared_general * 100, "%\n")

## Porcentaje de variación explicada por el modelo general: 78.36599 %
```

6. Dibuja el diagrama de dispersión de los datos y la recta de mejor ajuste.

Los diagramas se realizaron previamente.

La recta de mejor ajuste se refiere al modelo de regresión lineal que mejor predice la variable dependiente (Peso) en función de la variable independiente (Estatura) y, en el caso del modelo general, también del Sexo. La mejor recta de ajuste es aquella que maximiza el valor de R^2, que indica el porcentaje de la variación en la variable dependiente explicada por el modelo.

La mejor recta de ajuste es la del modelo general con la siguiente ecuación:

$$Peso = -74.7546 + 89.26035 * Estatura$$

Es la mejor recta de ajuste ya que tiene un R^2 del 78.27%, este modelo explica más de la variabilidad en el peso que los modelos separados para hombres y mujeres. Este modelo no solo considera la estatura, sino que también incluye el sexo, lo que mejora significativamente la capacidad del modelo para explicar el peso.

7. Interpreta en el contexto del problema cada uno de los análisis que hiciste.

Matriz de correlación: La estatura es un buen predictor del peso, especialmente en hombres. Sin embargo, en mujeres, la estatura por sí sola no explica el peso tan bien, lo que sugiere la necesidad de considerar otros factores.

Medidas estadísticas: Estas medidas ayudan a entender la distribución y variabilidad de las estaturas y pesos en la población estudiada, lo que es importante para la construcción de modelos predictivos.

Ecuaciones de regresión: El modelo general es el más eficaz porque tiene en cuenta tanto la estatura como el sexo, lo que lo convierte en una herramienta más precisa para predecir el peso en la población. Este modelo sugiere que, para una misma estatura, las mujeres tienden a pesar menos que los hombres, lo cual es coherente con las observaciones anteriores.

Verificación de la Significancia de los Modelos y Coeficientes: La significancia estadística asegura que los resultados obtenidos no son debidos al azar y que las relaciones entre estatura, sexo y peso son consistentes y fiables para la población estudiada.

R^2 El alto R^2 del modelo general sugiere que es el modelo más efectivo para predecir el peso en comparación con el resto de los modelos. En contextos de salud o nutrición, es importante entender cómo diferentes factores contribuyen al peso corporal.

A lo largo de los análisis, se observa que la estatura es un predictor fuerte del peso, especialmente en hombres, mientras que en mujeres otros factores podrían ser más influyentes. La inclusión del sexo en el modelo general mejora significativamente la capacidad predictiva del modelo, haciendo de este el más robusto y útil para predecir el peso en la población estudiada. Esto es relevante en contextos donde se busca entender mejor cómo las características físicas influyen en el peso corporal y, potencialmente, en la salud.

8. Interpreta en el contexto del problema:

a) ¿Qué información proporciona β̂0 sobre la relación entre la estatura y el peso de hombres y mujeres?

β_0 es el intercepto de la línea de regresión y tiene un valor teórico para el peso cuando la estatura es cero.

- Hombres: Un valor más negativo del intercepto (-83.68454) en comparación con el de las mujeres (-72.56045) sugiere que, para una misma estatura, los hombres tienden a tener un peso mayor en comparación con las mujeres cuando se analiza únicamente por la estatura.

- Mujeres: El intercepto menos negativo (-72.56045) sugiere que, al mantener la estatura constante, las mujeres suelen pesar menos que los hombres en este modelo.

b) ¿Cómo interpretas β̂1 en la relación entre la estatura y el peso de hombres y mujeres?

El coeficiente β_1 en una regresión lineal representa la pendiente de la línea de regresión. Este coeficiente muestra cómo cambia la variable dependiente (en este caso, el peso) en respuesta a un cambio en la variable independiente (estatura).

- Para Hombres $\beta_1 = 94.66$: La estatura tiene un impacto muy fuerte en el peso, con un aumento de 94.66 kg por cada metro adicional de estatura. Este es el valor más alto entre los modelos, lo que indica una relación muy pronunciada entre estatura y peso en hombres.

- Para Mujeres $\beta_1 = 81.15$: La estatura también tiene un impacto positivo en el peso, pero con un aumento más moderado de 81.15 kg por cada metro adicional. Esto sugiere que, aunque la estatura es un buen predictor del peso, su efecto es menor en comparación con los hombres.

- Modelo General $\beta_1 = 89.26$: Este valor intermedio refleja el impacto promedio de la estatura sobre el peso cuando se consideran ambos sexos. Este modelo proporciona una estimación más general que se ajusta a ambos géneros.

Significancia del modelo (segunda entrega)

Para la recta de regresión lineal de estatura (m) y peso (kg) de hombres y mujeres mexicanos, analiza si el modelo es apropiado para el conjunto de datos:

```r
# Ajustar el modelo de regresión general
modelo_interaccion <- lm(Peso ~ Estatura * Sexo, data)

summary(modelo_interaccion)
```

```
##
## Call:
## lm(formula = Peso ~ Estatura * Sexo, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -21.3256  -3.1107   0.0204   3.2691  17.9114
##
## Coefficients:
##                 Estimate Std. Error t value Pr(>|t|)
## (Intercept)      -83.685      9.735  -8.597   <2e-16 ***
## Estatura          94.660      5.882  16.092   <2e-16 ***
## SexoM             11.124     14.950   0.744    0.457
## Estatura:SexoM   -13.511      9.305  -1.452    0.147
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.374 on 436 degrees of freedom
## Multiple R-squared:  0.7847, Adjusted R-squared:  0.7832
## F-statistic: 529.7 on 3 and 436 DF,  p-value: < 2.2e-16
```

```r
# Obtener la ecuación de regresión
cat("Ecuación de regresión para el modelo general: Peso =",
coef(modelo_interaccion)[1], "+", coef(modelo_interaccion)[2], "*
Estatura\n")
```

```
## Ecuación de regresión para el modelo general: Peso = -83.68454 +
94.66024 * Estatura
```

```r
# Gráfico de dispersión
library(ggplot2)
```

```
## Warning: package 'ggplot2' was built under R version 4.3.3
```

```r
ggplot(data, aes(x = Estatura, y = Peso, color = Sexo)) +
  geom_point() +
  geom_smooth(method = "lm", aes(group = Sexo), se = FALSE) +
  labs(title = "Gráfico de Dispersión con Regresión por Sexo",
       x = "Estatura",
       y = "Peso") +
  theme_minimal()
```

```
## `geom_smooth()` using formula = 'y ~ x'
```

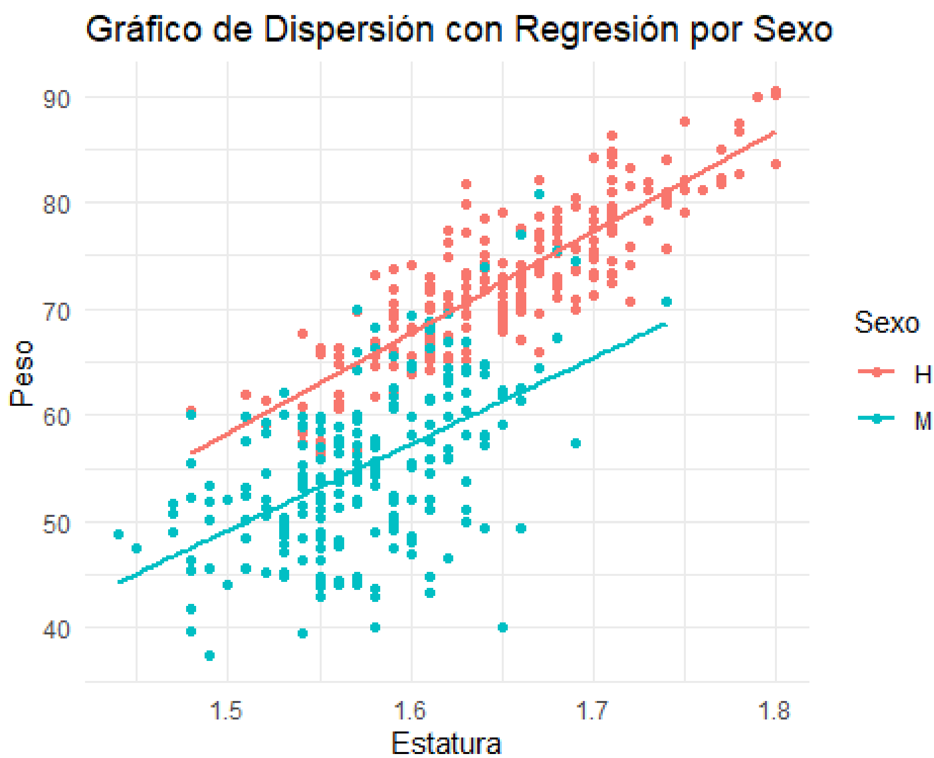

5. Verifica el modelo:

La matriz coefficients tiene la siguiente estructura general:

Filas: Cada fila representa un coeficiente del modelo.

- La primera fila ([1,]) corresponde al intercepto (β_0).
- La segunda fila ([2,]) corresponde al coeficiente de la primera variable predictora (β_1), que en este caso es Estatura.

Columnas:

- Primera columna ([, 1]): Contiene los valores estimados de los coeficientes ($\hat{\beta}$).
- Segunda columna ([, 2]): Contiene los errores estándar de los coeficientes.
- Tercera columna ([, 3]): Contiene los valores t, que son los estadísticos de prueba para los coeficientes.
- Cuarta columna ([, 4]): Contiene los valores p (p-values) asociados con cada coeficiente.

Hipótesis para el modelo:

$H_0: \beta = 0$ (El coeficiente del predictor en el modelo no es significativo)

$H_1: \beta \neq 0$ (El coeficiente del predictor en el modelo es significativo)

a) Verifica la significancia del modelo con un alfa de 0.03.

```
# Resumen del modelo para obtener valores p
summary_interaccion <- summary(modelo_interaccion)

# Extraer los valores p del modelo
p_value_interaccion <- pf(summary_interaccion$fstatistic[1],
summary_interaccion$fstatistic[2], summary_interaccion$fstatistic[3],
lower.tail = FALSE)

# Verificar la significancia con un alfa de 0.03
alpha <- 0.03



cat("Significancia global del modelo:\n")

## Significancia global del modelo:

if (p_value_interaccion < alpha) {
  cat("El modelo es significativo globalmente (p-value =",
p_value_interaccion, "<", alpha, ").\n")
} else {
  cat("El modelo no es significativo globalmente (p-value =",
p_value_interaccion, ">=", alpha, ").\n")
}

## El modelo es significativo globalmente (p-value = 5.93158e-145 < 0.03
).
```

b) Verifica la significancia de β̂i con un alfa de 0.03.

Hipótesis para el intercepto (β_0) los modelos:

$$H_0: \beta = 0 \quad \text{(El intercepto del modelo no es significativo)}$$
$$H_1: \beta \neq 0 \quad \text{(El intercepto del modelo es significativo)}$$

Hipótesis para la pendiente (β_1) en el modelo de hombres (Estatura):

$$H_0: \beta = 0 \quad \text{(La pendiente del modelo no es significativa)}$$
$$H_1: \beta \neq 0 \quad \text{(La pendiente del modelo es significativa)}$$

```
# Verificar la significancia de los coeficientes (betai) para modelo
general
cat("\n*** Significancia de los Coeficientes - Modelo con interaccion
***\n")
```

```
##
## *** Significancia de los Coeficientes - Modelo con interaccion ***

coeficientes_general <- summary_interaccion$coefficients
print(coeficientes_general)

##                 Estimate Std. Error    t value     Pr(>|t|)
## (Intercept)    -83.68454   9.734572 -8.5966329 1.484670e-16
## Estatura        94.66024   5.882365 16.0922078 4.524701e-46
## SexoM           11.12409  14.949668  0.7441028 4.572151e-01
## Estatura:SexoM -13.51113   9.304767 -1.4520657 1.472025e-01

# Evaluar significancia de cada coeficiente
for (i in 1:nrow(coeficientes_general)) {
  p_valor <- coeficientes_general[i, 4]
  cat(rownames(coeficientes_general)[i], "- Valor p:", p_valor)
  if (p_valor < 0.03) {
    cat(" -> Significativo\n")
  } else {
    cat(" -> No significativo\n")}
}

## (Intercept) - Valor p: 1.48467e-16 -> Significativo
## Estatura - Valor p: 4.524701e-46 -> Significativo
## SexoM - Valor p: 0.4572151 -> No significativo
## Estatura:SexoM - Valor p: 0.1472025 -> No significativo
```

c) Verifica el porcentaje de variación explicada por el modelo

```
# Extraer el valor de R-cuadrado para cada modelo
r_squared_interaccion <- summary_interaccion$r.squared

# Mostrar el porcentaje de variación explicada por el modelo
cat("Porcentaje de variación explicada por el modelo interacción:",
r_squared_interaccion * 100, "%\n")

## Porcentaje de variación explicada por el modelo interacción: 78.47011
%
```

Interpreta en el contexto del problema:

El modelo de regresión muestra que la estatura es un predictor fuerte y significativo del peso tanto para hombres como para mujeres mexicanos. Sin embargo, las diferencias en el peso promedio entre hombres y mujeres, así como la interacción entre la estatura y el sexo, no son estadísticamente significativas. El modelo tiene un buen ajuste con un R^2 elevado, explicando una gran parte de la variación en el peso, pero la falta de significancia en los coeficientes de sexo y la interacción sugiere que las diferencias entre géneros en este contexto podrían no ser tan pronunciadas como se podría suponer.

¿Qué información proporciona β̂0 sobre la relación entre la estatura y el peso de hombres y mujeres? Interpreta y compara entre este modelo con los 3 modelos anteriores.

El modelo con interacción no aporta una mejora significativa en términos de interpretación o ajuste, ya que la interacción no es significativa. El modelo general sin interacción es más simple y explica bien la relación entre estatura y peso. Los modelos separados para hombres y mujeres capturan las diferencias en cómo la estatura afecta el peso en cada género, pero el modelo general sin interacción ofrece una visión más compacta y fácil de interpretar.

Aunque β_0 no tiene un significado físico directo debido al rango de la estatura, es esencial para ajustar adecuadamente la línea de regresión en los modelos. La comparación muestra que, en ambos géneros, la estatura es un fuerte predictor del peso, pero la magnitud de esta relación difiere entre hombres y mujeres.

¿Cómo interpretas β̂i en la relación entre la estatura y el peso de hombres y mujeres? Interpreta y compara entre este modelo con los 3 modelos anteriores.

$\hat{\beta}_i$ representa la pendiente de la regresión, es decir, el cambio en el peso por cada unidad adicional de estatura.

Modelo para hombres: $\hat{\beta}_i = 94.66$. Por cada metro adicional de estatura, el peso de los hombres aumenta en promedio 94.66 kg.

Modelo para mujeres: $\hat{\beta}_i = 81.15$. Por cada metro adicional de estatura, el peso de las mujeres aumenta en promedio 81.15 kg, menos que en los hombres.

Modelo general sin interacción: $\hat{\beta}_i = 89.26$. Promedio ponderado que aplica para ambos géneros, reflejando una relación positiva entre estatura y peso.

Modelo general con interacción: $\hat{\beta}_i$ varía con la interacción (-13.51 no significativa), sugiriendo diferencias entre géneros, pero no estadísticamente relevantes.

Comparación: La pendiente es mayor en hombres, indicando que la estatura impacta más en su peso. El modelo sin interacción ofrece una estimación promedio, mientras que el modelo con interacción sugiere diferencias, pero no significativas.

c) Indica cuál(es) de los modelos probados para la relación entre peso y estatura entre hombres y mujeres consideras que es más apropiado y explica por qué.

Modelo con interacción vs. modelo sin interacción:

El modelo con interacción no muestra una mejora significativa respecto al modelo sin interacción, dado que la interacción no es estadísticamente significativa. Ambos modelos tienen un R^2 similar.

Modelos individuales para hombres y mujeres:

Los modelos para hombres y mujeres por separado muestran que la estatura es un mejor predictor del peso para los hombres (R^2=0.7171) que para las mujeres (R^2=0.2751). Esto sugiere que hay otros factores que pueden influir más en el peso de las mujeres, que no están capturados en este modelo simple.

Elección del mejor modelo:

Si se busca simplicidad y un ajuste razonablemente bueno, el modelo general sin interacción parece apropiado, dado que tiene un alto R^2 y coeficientes significativos. Si se necesita capturar posibles diferencias en la relación entre estatura y peso entre hombres y mujeres, los modelos separados podrían ser útiles, ya que muestran que la estatura es un predictor más fuerte del peso en hombres que en mujeres, y el modelo con interacción no aporta valor adicional en este caso. En conclusión, el modelo sin interacción es adecuado y proporciona un ajuste casi tan bueno como el modelo con interacción, pero de manera más simple.